

Inferencia Bayesiana

Módulo 1: Estadística

Tirada	Resultado
1	0
2	0
3	0
4	0
5	0
6	0
7	0
8	0
9	0
...	...



¿Está cargada la moneda?

Hipótesis/Modelo

Estadística: nos permite sacar conclusiones del mundo exterior

Test Binomial

scipy.stats.binom_test

Hipótesis: resultados distribuidos binomialmente

$$p(k|\theta) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$$

Hipótesis/Modelo

¿Cuál es la probabilidad de obtener m o más caras de n tiradas?

$$\sum_{k \geq m}^n p\left(k \middle| \theta = \frac{1}{2}\right)$$

¿Cuál es la probabilidad de obtener un resultado *tan o más extremo*?

$$\sum_{k=m}^n p\left(k \middle| \theta = \frac{1}{2}\right) + \sum_{k=0}^{n-m} p\left(k \middle| \theta = \frac{1}{2}\right)$$

¡El *p*-valor!

Test Binomial

`scipy.stats.binom_test`

$$p = \sum_{k=m}^n p\left(k \middle| \theta = \frac{1}{2}\right) + \sum_{k=0}^{n-m} p\left(k \middle| \theta = \frac{1}{2}\right)$$

p-valor para 12 caras de 12 tiradas...

$$p = \sum_{k=12}^{12} p\left(k \middle| \theta = \frac{1}{2}\right) + \sum_{k=0}^0 p\left(k \middle| \theta = \frac{1}{2}\right) = 0.00049$$

Si tiramos 6 veces la moneda,
y sale 6 veces cara...



¿diríamos que la moneda está cargada?

La “ciencia” hoy dice “sí”.

Más precisamente:

“Hay evidencia significativa de que está cargada ($p < 0.05$, test binomial)”

$$p = \sum_{k=6}^6 p\left(k \middle| \theta = \frac{1}{2}\right) + \sum_{k=0}^0 p\left(k \middle| \theta = \frac{1}{2}\right) = 0.03125$$

¡¿Es razonable esto?!

Estadística frecuentista...

$$p(6 \text{ caras} | \text{moneda honesta})$$

$$p(\text{datos} | \text{hipótesis})$$

Lo que queremos realmente..

$$p(\text{moneda honesta} | 6 \text{ caras})$$

$$p(\text{hipótesis} | \text{datos})$$

¡Inferencia bayesiana!


Estadística (o inferencia, o análisis de datos) bayesiana
como alternativa a la **estadística frecuentista o “clásica”**

Permite (¡exige!) incorporar nuestro
conocimiento previo

Podemos hacer afirmaciones sobre cuán
probable es que la moneda esté cargada
(prohibido en frecuentismo)

Probabilidad como *creencia*

inferencia bayesiana vs. estadística frecuentista



interpretación de la probabilidad

$p(\text{lo que yo quiera})$

p sólo para muestreo
("datos")

Críticas al frecuentismo: 2 niveles


- críticas de fondo:

- ignora conocimiento previo
- dilema (mezcla) Fisher (significance testing) vs. Neyman/Pearson (hypothesis testing)

- críticas al (ab)uso:

- convención de p: ¡1 de 20 estudios están mal!
- uso ciego en general (“imposible hacer ciencia”)
- *p hacking*
- crisis de reproducibilidad: 36 % papers replicados en psicología

confianza
percibida



Propuesta real: cambiar a $p < 0.005$

Inferencia Bayesiana

$$p(H, D) = p(D|H)p(H) = p(H|D)p(D)$$

$$p(H|D) = \frac{p(D|H)p(H)}{p(D)}$$

posterior *likelihood* *prior*

The diagram illustrates the components of the posterior probability formula. The term $p(H|D)$ is enclosed in a purple box. The numerator $p(D|H)p(H)$ is enclosed in a red box. Three arrows point from the labels "posterior", "likelihood", and "prior" to the corresponding terms in the formula.

Teorema de Bayes

Acumulación de Evidencia


$$p(H|D_1) = \frac{p(D_1|H)P(H)}{p(D_1)}$$

$$p(H|D_2D_1) = \frac{p(D_2|HD_1)P(H|D_1)}{p(D_2|D_1)}$$

“The posterior is the new prior”

Redes Bayesianas/Modelos Jerárquicos

$$p(B, E, A, P, R) = p(B)p(E|B)p(A|B, E)p(P|A, B, E)p(R|P, A, B, E)$$



$$p(B, E, A, P, R) = p(B)p(E)p(A|B, E)p(P|A)p(R|E)$$

Inferencia Bayesiana

- Incorpora conocimiento *a priori* en forma natural (¡y obligatoria!)
- Elude los *p values*
- Responde en términos de distribuciones de probabilidad (nuestro *grado de creencia*)
- Datos secuenciales: modelo de aprendizaje
- Redes, modelos jerárquicos, estructura x estadística

“Formalización del sentido común”

DID THE SUN JUST EXPLODE?

(IT'S NIGHT, SO WE'RE NOT SURE.)

THIS NEUTRINO DETECTOR MEASURES WHETHER THE SUN HAS GONE NOVA.

THEN, IT ROLLS TWO DICE. IF THEY BOTH COME UP SIX, IT LIES TO US. OTHERWISE, IT TELLS THE TRUTH.

LET'S TRY.

DETECTOR! HAS THE SUN GONE NOVA?

(ROLL)

YES.




FREQUENTIST STATISTICIAN:

THE PROBABILITY OF THIS RESULT HAPPENING BY CHANCE IS $\frac{1}{36} = 0.027$.



SINCE $p < 0.05$, I CONCLUDE THAT THE SUN HAS EXPLODED.



BAYESIAN STATISTICIAN:



¿Por qué ahora?
Bayes/Laplace siglo XVIII
Keynes 1920s
de Finetti 1930, *Probabilismo*



computadoras + algoritmos



uso práctico

inferencia bayesiana vs. estadística frecuentista

abordaje moderno: convivencia

- proyectos de largo plazo, con un especialista en el campo
 - fuerte en modelado
 - ¿más ‘honesta’?
- *software bundles*
 - uso repetido
 - modelado mínimo



Pero entonces...

¿diríamos que la moneda está cargada?

¡Usemos Bayes!

$$p(\text{moneda honesta} | 6 \text{ caras})$$

Repasso de probabilidad

probabilidad conjunta, condicional

$$p(\theta, y) = p(\theta|y)p(y)$$

simétrica

$$p(\theta, y) = p(y|\theta)p(\theta)$$

marginalización

$$p(y) = \int p(y, \theta)d\theta$$

simétrica

$$p(\theta) = \int p(y, \theta)dy$$

θ discreta

$$p(y) = \sum_{\theta} p(y, \theta)$$

Independencia
 $p(A, B) = p(A)p(B)$

Independencia Condicional
 $p(A, B|C) = p(A|C)p(B|C)$

$$\nRightarrow p(A, B) = p(A)p(B) \qquad \Rightarrow p(A|B, C) = p(A|C)$$

“Desarmando” la conjunta...


$$p(A, B, C) = p(A|B, C)p(B|C)p(C)$$

$$p(A, B, C) = p(B|A, C)p(A|C)p(C)$$

$$p(A, B, C) = p(C|A, B)p(B|A)p(A)$$

...

Muestras vs. distribuciones




$x \sim \text{Distrib}$ ("x" distribuida como ...)

$$p(x) = \text{pdf}(\text{Distrib})$$

Con muchas muestras, puedo *aproximar* la pdf/pmf...

Teorema de Bayes

$$p(H|D) = \frac{p(D|H)p(H)}{p(D)} = \frac{p(D|H)p(H)}{\int p(D|H)p(H)dH}$$



Likelihood: distribución Binomial

$$p(k|\theta) = \binom{n}{k} \theta^k (1-\theta)^{n-k}$$

$$k \sim \text{Binomial}(\theta, n)$$

k sucesos de n “tiradas”, con probabilidad de suceso theta

Modelo Beta-Binomial




likelihood:

$$p(k|\theta) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$$

$$k \sim \text{Binomial}(\theta, n)$$


prior:

$$p(\theta) \dots$$



Prior: distribución Beta

$$p(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} \quad \alpha, \beta > 0 \quad \theta \in [0, 1]$$



$$E[\theta] = \frac{\alpha}{\alpha + \beta}$$

¿Cómo cambia si los parámetros difieren?

Modelo Beta-Binomial



likelihood:

$$p(k|\theta) = \binom{n}{k} \theta^k (1-\theta)^{n-k}$$


$$k \sim \text{Binomial}(\theta, n)$$


prior:

$$\theta \sim \text{Uniform}(0, 1) = \text{Beta}(1, 1)$$

$$\theta \sim \text{Beta}(100, 100)$$

posterior con Bayes:
$$p(\theta|k) = \frac{p(k|\theta)p(\theta)}{p(k)}$$






prior

$\theta \sim \text{Uniform}(0, 1) = \text{Beta}(1, 1)$

$\theta \sim \text{Beta}(100, 100)$

posterior
(luego de 6 caras)



¡¿Y ENTONCES?!



¿diríamos que la moneda está cargada?

¡Depende del *prior*!

¿Y está bien esto? ¡Sí! Va a cambiar con quién me de la moneda, etc.. Es más:

No hay inferencia sin hipótesis

MODELO



DATOS

```
graph LR; A["DATOS"] --> B["Explicación"]
```

Explicación

posterior



Predicción

posterior predictive

$$p(\theta|y) \propto p(y|\theta)p(\theta)$$

↓

posterior

prior


likelihood

*prior
predictive*

$$p(y) = \int p(y, \theta) d\theta = \int p(y|\theta)p(\theta)d\theta$$

posterior predictive

$$\begin{aligned}
 p(\tilde{y}|y) &= \int p(\tilde{y}, \theta|y) d\theta \\
 &= \int p(\tilde{y}|\theta, y)p(\theta|y)d\theta \\
 &= \int p(\tilde{y}|\theta)p(\theta|y)d\theta \rightarrow \text{promedio con mi posterior!}
 \end{aligned}$$



pymc3

- <http://docs.pymc.io/>
- Modelado Bayesiano y Machine Learning Estadístico
- ```
import pymc3 as pm
my_model = pm.Model()
with my_model:
 theta = pm.Beta(...)
...
trace = pm.sample()
```

